大数据分析实践
课程实验报告

实验项目-BERT 实践

专业班级：22 级公信

学　　号：202200120100

姓　　名：徐瑞良

报告日期：2025 年 11 月 7 日

目　录

实验 4 数据质量实践

4.1 实验目标

对动手实践利用机器学习方法分析大规模数据有进一步了解，并学习如何利用远程环境进行工程代码的调试.

4.2 实验环境

远程带 GPU 的服务器，且 CUDA 版本大于 10.0，其他包需求如下:

torch==1.7.0

transformers==4.18.0

4.3 数据集

MRPC (Microsoft Research Paraphrase Corpus) 包含了 5800 个句子对，有的是同义的，有的是不同义的，是否同义由一个二元标签进行描述.

数据集下载链接:https://www.microsoft.com/en-us/download/details.aspx?id=52398

4.4 实验步骤

4.4.1 配置环境

a. 使用 SSH 连接远程服务器，例如可以使用 XSHELL

b. 从 Anaconda 的官网下载 for Linux 的安装包，用 FTP 传输至服务器上想要的安装位置，并使用 bash 命令在该位置进行安装

c. 使用 conda create 命令创建 base 环境以外的虚拟环境

d. 使用 conda activate 命令进行虚拟环境的切换

e. 安装所需要的包

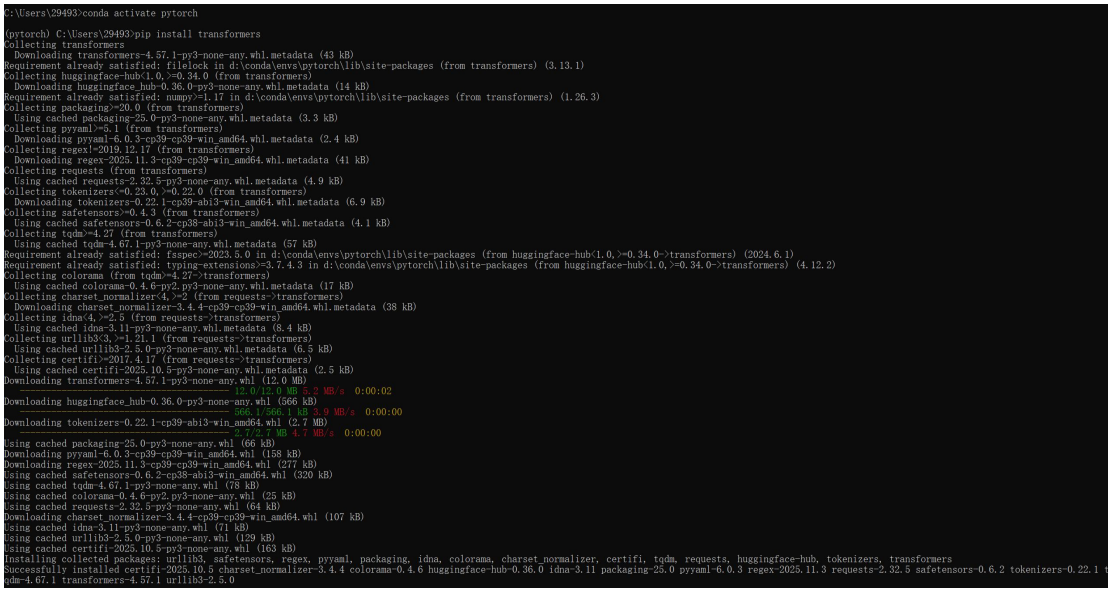

4.4.2 对 PyCharm 配置(该步骤参考的 PyCharm 版本为 2021.3.3 Professional Edition, 日后的版本可能操作略有不同):

a. 下载 PyCharm 专业版, 并打开已有的代码项目
b. 配置 SSH configuration, 连接服务器
c. 设置 deployment, 在其中设置路径映射
d. 配置 Python Interpreter, 使用已经配置好的 deployment 的配置
e. 设置 deployment 自动同步, 并手动进行第一次上传已有的代码.

4.4.3 熟悉 PyTorch 框架下, 利用预训练的 transformers 的预训练 BERT 模型对 MRPC 数据集进行同义预测的 pipeline. 尝试理解数据是如何预处理, 模型是怎么读入数据, 是如何进行推理, 如何进行评价的.

(代码逻辑: 对 BERT 进行微调, 每个句子对用 BERT 指定分隔符 [SEP] 连接后, 通过 BERT 得到合成句子的 representation. 再通过通过一个两层的多层感知机得到分类结果. 这里预训练 BERT 模型使用的是 HuggingFace 的 BERT-base-uncased)

4.4.3.1 数据预处理流程

通过 MRPCDataset 类实现，核心为：加载训练 / 测试数据并跳过表头，解析提取标签与句子对，过滤无效数据后按 PyTorch Dataset 接口规范存储，最终将样本整理为批次，标签转换为 Tensor 格式，适配模型输入。

4.4.3.2 模型数据读取与训练流程

1. 数据加载：以 DataLoader 封装 MRPCDataset 实例，配置 batch_size=16、数据打乱及 GPU 传输加速参数，确保批次格式统一。

2. 模型初始化：加载 bert-base-uncased 分词器与预训练模型并移至 GPU；初始化两层 MLP 分类头（输入维度 768、输出维度 1），同样部署 GPU。

3. 训练配置：采用 Adam 优化器（BERT 学习率 2e-5、MLP 学习率 1e-4）、BCELoss 损失函数及二分类准确率计算函数。

4. 训练循环：迭代批次数据，经分词器编码（含填充、截断、[SEP] 分隔）后输入 BERT，提取 [CLS] 语义表征传入 MLP 输出预测概率；通过反向传播计算梯度，梯度裁剪后更新模型参数。

4.4.3.3 推理与评价流程

对新句子对重复编码与特征提取流程，通过 torch.round () 将 MLP 输出概率映射为 0/1 分类结果，完成同义预测。

以准确率为核心指标，训练中每 10 批次打印实时损失与准确率，每个 epoch 结束后计算平均指标，评估模型训练效果。

4.4.3.4 注意事项

由于预训练 BERT 模型托管在国外服务器，国内网络直接下载易超时，通过设置环境变量 `os.environ["HF_ENDPOINT"] = "https://hf-mirror.com"` 切换

至国内镜像源，或手动下载模型文件（config.json、pytorch_model.bin、vocab.txt）至本地文件夹，通过本地路径加载模型。

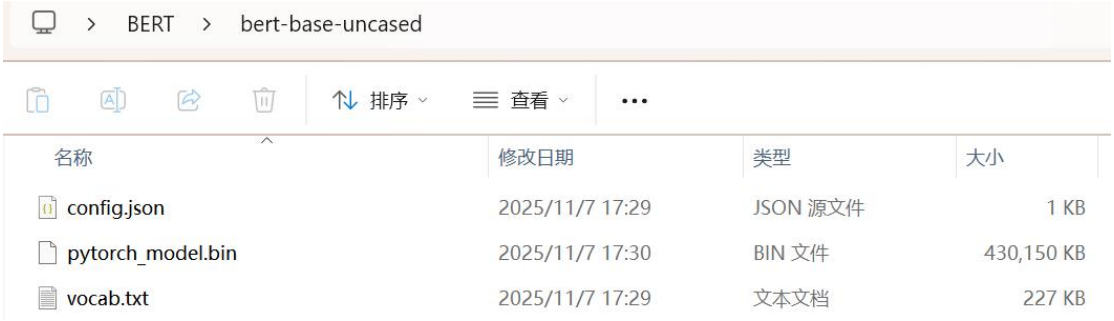

4.5 心得与体会

本次实验让我深入掌握了 BERT 微调实现句子对语义匹配的核心流程。从环境配置、远程开发部署到数据预处理、模型训练全链路实践，理解了预训练模型特征提取与分类头适配的关键逻辑。通过解决依赖冲突、数据格式适配等问题，切实体会到工程实现与理论结合的重要性，也深化了对 PyTorch 框架及 Hugging Face 工具链的实操认知。